

Санкт-Петербургский Политехнический Университет
Высшая школа прикладной математики и вычислительной физики, ФизМех
01.03.02 Прикладная математика и информатика

Отчет по лабораторной работе № 4
"Эмпирическая функция распределения и ядерные оценки
плотности"

Выполнил студент гр. 5030102/30201
Преподаватель

Гусев Г. А.
Баженов А. Н.

Постановка задачи

Задание: Сгенерировать выборки объёмом $n = 20, 60, 100$. Построить на них:

1. Эмпирическую функцию распределения (э. ф. р.) и теоретическую функцию распределения.
2. Ядерную оценку плотности (ядро — гауссово) и теоретическую плотность.

Цели и задачи:

- Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
- Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

Исследуются следующие распределения:

1. Нормальное $N(x; 0, 1)$
2. Коши $C(x; 0, 1)$
3. Лапласа $L(x; 0, 1/\sqrt{2})$
4. Пуассона $P(k; 10)$
5. Равномерное $U(x; -\sqrt{3}, \sqrt{3})$

Теоретическая часть

- Нормальное распределение

$$Normal(x, 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

- Распределение Коши

$$Cauchy(x, 0, 1) = \frac{1}{\pi} \frac{1}{x^2 + 1}$$

- Распределение Лапласа

$$Laplace\left(x, 0, \frac{1}{\sqrt{2}}\right) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

- Распределение Пуассона

$$Poisson(k, 10) = \frac{10^k}{k!} e^{-10}$$

- Равномерное распределение

$$Uniform(x, -\sqrt{3}, \sqrt{3}) = \begin{cases} \frac{1}{2\sqrt{3}} & \text{при } |x| \leq \sqrt{3} \\ 0 & \text{при } |x| > \sqrt{3} \end{cases}$$

- Эмпирическая функция распределения

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x), \text{ где } I(.) - \text{индикаторная функция}$$

- Теорема Гливено-Кантелли

$$\lim_{n \rightarrow \infty} \sup_x |F_n(x) - F(x)| = 0$$

- Ядерная оценка плотности

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \text{ где } K(.) - \text{ядро}$$

- Ядро Гаусса

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$$

- Ширина окна Сильвермана

$$h = 1.06 \hat{\sigma} n^{-\frac{1}{5}}, \text{ где } \hat{\sigma} - \text{среднеквадратичное отклонение выборки}$$

- Ширина окна Сильвермана (робастная версия)

$$h = 0.9 \min(\hat{\sigma}, \frac{IQR}{1.34}) n^{-\frac{1}{5}}$$

Реализация

Язык программирования: Python 3.14

Сторонние библиотеки:















`numpy` – генерация случайных выборок

`matplotlib.pyplot` – построение графиков


`scipy.stats` – теоретические распределения

Код: https://github.com/Gusen14ka/MatStat_Lab4


Результаты




Распределение Laplace, n=20




Распределение Laplace, n=60




Распределение Laplace, n=100




Распределение Poisson, n=20




Распределение Poisson, n=60




Распределение Poisson, n=100




Распределение Poisson, n=20




Распределение Poisson, n=60




Распределение Poisson, n=100




Распределение Uniform, n=20




Распределение Uniform, n=60




Распределение Uniform, n=100




Распределение Uniform, n=20






Распределение Uniform, n=60



Распределение Uniform, n=100





Обсуждение

1) Влияние объёма выборки на приближение ЭФР к теоретической функции

При $n=20$ эмпирическая функция распределения имеет выраженную ступенчатость и заметные отклонения от теоретической функции.

При $n=60$ отклонения уменьшаются, графики становятся более согласованными.

При $n=100$ ЭФР практически совпадает с теоретической функцией распределения.

Для распределения Коши отклонения остаются более заметными из-за тяжёлых хвостов и возможных выбросов.

Вывод: увеличение объёма выборки приводит к более точному приближению эмпирической функции распределения к теоретической.

2) Сравнение ядерной оценки плотности и гистограммы

Гистограмма чувствительна к выбору числа интервалов и при малых n имеет неровный вид.

Ядерная оценка (гауссово ядро) даёт более гладкую аппроксимацию и в большинстве случаев лучше совпадает с теоретической плотностью.

Для Равномерного распределения ядерная оценка сглаживает резкие границы плотности.

Для распределений с тяжёлыми хвостами (например, распределение Коши) обе оценки требуют большего объёма выборки для устойчивого результата.

Вывод: ядерная оценка плотности в целом даёт более качественное приближение по сравнению с гистограммой, особенно при увеличении объёма выборки.

3) Разное число слагаемых в ядерной оценке

Сравнение ядерных оценок с разным числом слагаемых (гауссовский ядер) наглядно показывает, как увеличение числа слагаемых сглаживает график ядерной оценки и приближает её к теоретическим значениям.

4) ЭФР, построенная по гистограмме

Графики ЭФР, построенных по гистограмме, наглядно показывают, что увеличение выборки приближает ЭФР к теоретическим значениям. Однако, в сравнении с ЭФР, построенной прямым путём, ЭФР, построенная по гистограмме, проигрывает в точности приближения и имеет больший шаг.

5) Сравнение ширины окна

Для Коши сравнение ширины окон полученных с помощью правила Сильвермана и робастного правила Сильвермана, показывает, что выбор правильного h играет решающую роль в корректности построенной оценки.

Выводы

- 1) Увеличение объёма выборки существенно улучшает приближение эмпирической функции распределения к теоретической.
- 2) Ядерная оценка плотности в большинстве случаев даёт более качественное и устойчивое приближение к истинной плотности по сравнению с гистограммой.
- 3) Для распределений с тяжёлыми хвостами (распределение Коши) требуется большой объём выборки для получения устойчивых оценок.
- 4) При малых объёмах выборки статистические оценки обладают высокой вариативностью и чувствительны к случайным флуктуациям.
- 5) Выбор h является ключевым фактором, влияющим на корректность ядерной оценки: если брать слишком маленькую h , то оценка будет рванной – каждая точка рассматривается очень локально. Если h слишком большая, то оценка становится почти плоской, теряется структура/форма распределения.